

Analisi di Co-occorrenza di Terremoti con Scala e Apache Spark

Progetto per l'esame di Scalable and Cloud Programming, A.A. 2025-26

Alberto Zini, matricola 0001007558

Repository: <https://github.com/Sh0wBlack32/SCP-earthquake-cooccurrence>

1. Descrizione del problema

L'obiettivo del progetto è realizzare, in Scala e Apache Spark, un'analisi di co-occorrenza di eventi sismici in località diverse. Data una serie storica di terremoti, ciascuno caratterizzato da latitudine, longitudine e istante temporale, si vuole individuare la coppia di località che co-occorrono più spesso, ovvero la coppia di aree in cui si registrano eventi sismici nella stessa finestra temporale (un giorno) nel maggior numero di giorni distinti. Il risultato richiesto è la coppia vincente e l'elenco, in ordine crescente, delle date in cui i due eventi co-occorrono.

Poiché la posizione esatta di un evento non è rilevante quanto l'area in cui esso si verifica, latitudine e longitudine vengono arrotondate alla prima cifra decimale (arrotondamento al valore più vicino). Questo introduce duplicati (più eventi nello stesso giorno che ricadono nella stessa "cella" geografica arrotondata) che devono essere deduplicati prima di generare le coppie, altrimenti si rischia di individuare come vincente una coppia di eventi nella stessa cella geografica.

1.1 Dataset

Il dataset è composto da record (latitude, longitude, date) in formato CSV con intestazione. Sono disponibili due versioni: una versione ridotta, usata per i test in locale e sulla configurazione solo-master, e una versione completa (1.47M record), usata per l'esecuzione e la valutazione delle prestazioni su Google Cloud DataProc.

1.2 Risultato

Sul dataset completo, entrambi gli approcci individuano la stessa coppia vincente, **((38.8, -122.8), (38.8, -122.7))**, con **10032 date di co-occorrenza**, dal 1990-01-05 al 2023-07-29 (33.6 anni). Le coordinate ricadono nell'area di The Geysers, in California del Nord, il più grande campo geotermico al mondo, dove l'estrazione geotermica induce una sismicità indotta pressoché quotidiana da decenni: la coppia co-occorre nell'81.8% dei giorni dell'intero intervallo, un risultato coerente col dominio applicativo e non un artefatto dei dati o dell'algoritmo.

2. Approccio implementativo

L'elaborazione segue lo schema map-reduce ed è interamente distribuita tramite RDD di Spark. La pipeline comune ai due approcci è la seguente:

- lettura del CSV e arrotondamento di lat/lon alla prima cifra decimale;
- troncamento del timestamp alla data (YYYY-MM-DD);
- deduplica delle coppie (località, data) generate dall'arrotondamento;
- generazione, per ogni giorno, di tutte le coppie canoniche di località (loc_i, loc_j) con loc_i < loc_j;
- deduplica delle coppie (coppia, data);
- conteggio delle co-occorrenze per coppia e individuazione del massimo;
- raccolta e ordinamento delle date per la coppia vincente.

2.1 Approccio 1: groupByKey

Le località vengono raggruppate per data con **groupByKey**; per ogni giorno, le coppie candidate vengono generate localmente (in memoria, sul singolo executor) a partire dalla lista di località distinte osservate quel giorno. È l'approccio più efficiente quando il numero di eventi per giorno è contenuto, poiché evita uno shuffle aggiuntivo per generare le coppie.

2.2 Approccio 2: Self-Join

In alternativa, le coppie vengono generate tramite un self-join distribuito dell'RDD chiave-valore (data, località) con se stesso, filtrando poi le coppie con $loc1 < loc2$ per eliminare simmetrie e auto-coppie. Questo approccio distribuisce il lavoro di generazione delle coppie su tutto il cluster invece di concentrarlo sul singolo executor che gestisce un dato giorno, a costo di uno shuffle più oneroso; può risultare preferibile quando i giorni con molti eventi (skew) rendono costoso il groupByKey.

3. Setup sperimentale

Le prove sono state eseguite su Google Cloud DataProc (regione europe-west1), con cluster di 2, 3 e 4 worker, boot disk da 240 GB, memoria executor/driver aumentata esplicitamente rispetto ai default di DataProc (necessario per contenere lo shuffle spill sulla chiave skewata, vedi Sezione 4). Il cluster a 2 worker usa macchine **n2-standard-4** (4 vCPU/16 GB); per i cluster a 3 e 4 worker è stato necessario passare a **n2-standard-2** (2 vCPU/8 GB) a causa di un vincolo di quota GCP scoperto durante gli esperimenti stessi, descritto in dettaglio in Sezione 4. Il dataset completo e il JAR dell'applicazione sono stati caricati su un bucket Google Cloud Storage e referenziati tramite URI gs:// nei job Spark.

Le varianti con repartition(16)/repartition(32) sul cluster a 4 worker, previste nel piano sperimentale, non sono state eseguite per limiti di tempo e di quota (vedi nota sotto la tabella dei tempi): la quota globale del progetto education si è rivelata sufficiente solo per un numero limitato di run cloud completi, e si è scelto di privilegiare la copertura dei tre punti di scalabilità sul numero di worker rispetto alle varianti di partizionamento.

Versioni e librerie

Componente	Versione
Scala	2.12.17
Apache Spark	3.3.2
sbt	1.9.7
Piattaforma	Google Cloud DataProc (europe-west1)

4. Analisi di scalabilità e prestazioni

Durante gli esperimenti è emerso un vincolo non documentato in anticipo: il progetto GCP education-tier impone una quota **globale** (non solo per regione) di 12 vCPU per l'intero progetto (metrica `compute.googleapis.com/cpus_all_regions`, verificabile con `gcloud compute project-info describe`). Con n2-standard-4, un cluster a 2 worker (1 master + 2 worker × 4 vCPU) usa già l'intera quota disponibile: non è possibile creare cluster a 3 o 4 worker con lo stesso tipo di macchina senza un aumento di quota, che si è rivelato non ottenibile automaticamente su un progetto così recente (motivo restituito dall'API: `NOT_ENOUGH_USAGE_HISTORY`). Si è quindi proceduto usando n2-standard-2 (2 vCPU / 8 GB) per i cluster a 3 e 4 worker, che introduce una variabile di confondimento esplicita (i tre punti della curva non condividono lo stesso hardware per nodo), dichiarata qui per trasparenza metodologica.

Worker (macchina)	Partizioni	Approccio	Tempo (s)
2 (n2-std-4)	default	groupByKey	4451.7 (74.2 min)
2 (n2-std-4)	default	self-join	4619.0 (77.0 min)
3 (n2-std-2)*	default	groupByKey	9647.2 (160.8 min)
4 (n2-std-2)*	default	groupByKey	11830.1 (197.2 min)

* macchina più piccola (n2-standard-2) per il vincolo di quota descritto sopra, non per scelta progettuale.

4.1 Scalabilità (strong scaling)

Il risultato più significativo non è la velocità assoluta, ma la sua direzione: passando da 3 a 4 worker il tempo di esecuzione **aumenta** (da 160.8 a 197.2 minuti) invece di diminuire, nonostante il cluster a 4 worker abbia più nodi. Questo è coerente con la natura del dataset: la coppia vincente co-occorre nell'81.8% dei giorni in un intervallo di 33.6 anni (10032 su 12259 giorni), quindi la data-chiave a cui è associata gran parte del lavoro di generazione/deduplica delle coppie è fortemente skewata. Sia `groupByKey` sia `.join()` di Spark RDD ripartizionano per chiave: tutti i valori di una singola chiave finiscono in un numero di task che non cresce aggiungendo worker (a differenza delle `DataFrame Spark SQL`, dove l'Adaptive Query Execution gestisce lo skew-join automaticamente ridistribuendo la chiave calda su più task). Aggiungere nodi, in questo scenario, aumenta solo l'overhead di coordinamento e di shuffle di rete tra più macchine, senza alcun guadagno di parallelismo reale sulla parte di lavoro che conta di più: da qui il rallentamento anziché lo speedup atteso da un naive strong scaling. Il confronto è inoltre confondato dal cambio di macchina (n2-standard-4 → n2-standard-2, vedi sopra): non si può quindi escludere che una parte del rallentamento 2→3 worker derivi anche dalla minore memoria per nodo (16 GB → 8 GB, con conseguente maggiore spill su disco), ma il peggioramento 3→4 worker (stessa macchina, più nodi) isola in modo pulito l'effetto dello skew dall'effetto della memoria.

4.2 Effetto del partizionamento

Non essendo state eseguite le varianti di repartition (vedi nota in Sezione 3), non è possibile riportare un confronto quantitativo. Sulla base dell'analisi teorica in Sezione 4.1, ci si aspetterebbe che un maggior numero di partizioni non aiuti in modo sostanziale in questo caso: il problema non è un numero insufficiente di partizioni in generale, ma la concentrazione del carico su una singola chiave logica indipendentemente da quante partizioni totali esistono: un maggior `repartition()` ridistribuirebbe meglio le chiavi poco attive, ma non la chiave dominante, che resta comunque processata da un numero limitato di task.

4.3 Confronto tra i due approcci

A parità di worker (2, unico punto testato per entrambi con la stessa macchina), il self-join è risultato leggermente più lento del `groupByKey` (77.0 contro 74.2 minuti, +3.8%). Questo è coerente con quanto anticipato in Sezione 2.2: il self-join produce un prodotto cartesiano di tutte le località osservate nello stesso giorno prima di filtrare le coppie valide, generando quindi più lavoro intermedio del `groupByKey` (che invece genera le coppie già filtrate direttamente in memoria per ogni giorno). La differenza è comunque modesta a 2 worker; non è stato possibile verificare se si amplifichi a 3/4 worker per gli stessi limiti di tempo/quota descritti sopra. La correttezza del self-join è comunque stata verificata in ogni condizione testata (campione ridotto e cluster a 2 worker): risultato identico al `groupByKey` in tutti i casi.

5. Conclusioni

L'implementazione (in entrambe le varianti) individua correttamente la coppia di location arrotondate ((38.8, -122.8), (38.8, -122.7)), un'area compatibile con il campo geotermico di The Geysers in California del Nord, come la coppia con il maggior numero di co-occorrenze giornaliere (10032, dal 1990-01-05 al 2023-07-29). Il `groupByKey` si è dimostrato leggermente preferibile al self-join nell'unico confronto diretto disponibile (2 worker), coerentemente con il minor lavoro intermedio prodotto. Il risultato sperimentale più rilevante è tuttavia negativo rispetto alle aspettative di scalabilità naive: con una chiave fortemente skewata, aggiungere worker non solo non velocizza l'elaborazione oltre un certo punto, ma può peggiorarla per il maggiore overhead di rete, poiché né `groupByKey` né self-join su RDD offrono un meccanismo di redistribuzione delle chiavi calde. Un miglioramento naturale, lasciato come lavoro futuro, sarebbe la riformulazione del problema con `DataFrame/Dataset Spark SQL` per beneficiare dell'Adaptive Query Execution (skew join automatico), oppure l'applicazione manuale di una tecnica di key salting sulla chiave data per distribuire esplicitamente il lavoro della chiave calda su più task anche in RDD puro.

Codice sorgente: <https://github.com/Sh0wBlack32/SCP-earthquake-cooccurrence> (istruzioni per l'esecuzione su DataProc nel README del repository).